

Figure 6. Les six patch-sets ne mesurent pas le même benchmark


(a) désaccord dur, en nombre de tâches

A : supprime la tâche	browser-use 12/2024	—	15	6	12	29	37
	Convergence 02/2025	2	—	3	10	20	27
	Magnitude 07/2025	4	15	—	13	25	37
	Fara 08/2025	9	22	10	—	26	33
	Alumnium 03/2026	2	6	1	6	—	15
	Skyvern 05/2026	5	6	5	5	5	—

browser-use
Convergence
Magnitude
Fara
Alumnium
Skyvern

B : conserve la tâche telle quelle

(b) accord entre les six annotateurs



nombre d'annotateurs signalant la tâche